

# **LAPORAN PROYEK UAS**

## **Pemodelan ABSA dari Review Google Places**

Multilabel Text Classification dan Named Entity Recognition  
(NER)



Oleh :

Beyond Revata Hwang (230712326)

Ferrincia Avril (230712368)

**Program Studi Informatika**

**Universitas Atma Jaya Yogyakarta**

**Tahun Akademik 2025/2026**

## A. Deskripsi Dataset

Dataset yang digunakan merupakan hasil proyek UTS berupa anotasi Aspect-Based Sentiment Analysis (ABSA) dari review Google Places berbahasa Indonesia. Dataset dianotasi menggunakan tool Prodigy dan disimpan dalam format JSONL (db\_nlp5\_genap2526.jsonl).

### a) Sumber dan Komposisi Data

Dataset terdiri dari review pada domain usaha sandang. Anotasi yang digunakan dalam proyek ini berasal dari satu annotator dengan ID nlp5\_genap2526-230712326. Hanya record dengan status answer: accept yang dimasukkan ke pipeline pemodelan, sehingga total data yang digunakan adalah 1.013 record.

| Atribut                        | Detail                      |
|--------------------------------|-----------------------------|
| Total record (accepted)        | 1.013 review                |
| Annotator                      | nlp5_genap2526-230712326    |
| Format file                    | JSONL (Prodigy output)      |
| Domain                         | Kuliner, Sandang, Kerajinan |
| Rata-rata token per review     | 15,1 token (median: 11)     |
| Panjang token maksimum         | 74 token (semua < 128)      |
| Record dengan span NER         | 992 record (97,9%)          |
| Record tanpa span (OOT/kosong) | 21 record (2,1%)            |

### b) Struktur Record

Setiap record JSONL memiliki field utama sebagai berikut:

- text : teks review asli berbahasa Indonesia
- tokens : list token dengan offset karakter (start, end)
- spans : list span entitas, token\_start (inclusive), token\_end (inclusive), label
- accept : list label multilabel yang diberikan annotator
- answer : status anotasi (accept / ignore)

## B. Skema Label

### a) Label Multilabel Text Classification (Review-Level)

Terdapat 13 label ABSA yang digunakan pada level review. Setiap review dapat memiliki lebih dari satu label (multi-hot encoding).

| No. | Label              | Keterangan                                                     |
|-----|--------------------|----------------------------------------------------------------|
| 1   | PRODUCT_POSITIVE   | Opini positif terhadap produk/jasa utama                       |
| 2   | PRODUCT_NEGATIVE   | Opini negatif terhadap produk/jasa utama                       |
| 3   | PRODUCT_NEUTRAL    | Penyebutan produk/jasa tanpa sentimen jelas                    |
| 4   | PRICE_POSITIVE     | Opini positif terhadap harga/nilai/kemurahan                   |
| 5   | PRICE_NEGATIVE     | Opini negatif terhadap harga/nilai/kemahalan                   |
| 6   | PRICE_NEUTRAL      | Penyebutan harga tanpa sentimen jelas                          |
| 7   | PLACE_POSITIVE     | Opini positif terhadap tempat, suasana, lokasi, atau fasilitas |
| 8   | PLACE_NEGATIVE     | Opini negatif terhadap tempat, suasana, lokasi, atau fasilitas |
| 9   | PLACE_NEUTRAL      | Penyebutan tempat tanpa sentimen jelas                         |
| 10  | PROMOTION_POSITIVE | Opini positif terhadap promosi/diskon/paket                    |
| 11  | PROMOTION_NEGATIVE | Opini negatif terhadap promosi/diskon/paket                    |
| 12  | PROMOTION_NEUTRAL  | Penyebutan promosi tanpa sentimen jelas                        |
| 13  | OUT_OF_TOPIC       | Review tidak relevan dengan keempat aspek ABSA                 |

b) Skema Tag NER (Token-Level)

Skema BIO (Beginning-Inside-Outside) digunakan untuk anotasi token-level. Label span pada dataset Prodigy mempertahankan informasi sentimen sehingga terdapat 13 entitas unik. Token yang bukan bagian dari entitas diberi tag O.

- B-<LABEL> : token pertama (Beginning) dari span entitas
- I-<LABEL> : token lanjutan (Inside) dari span entitas
- O : token di luar entitas (Outside)

Total unique BIO tag: 27 (O + 13 B- + 13 I-).

Contoh: B-PRODUCT\_POSITIVE, I-PRICE\_NEGATIVE, O.

## C. Alur Eksperimen

### a) Proyek A : Multilabel Text Classification

#### i. Data Loading dan Preprocessing

- Baca JSONL, filter annotator 230712326, status accept → 1.013 record
- Text cleaning: lowercase, hapus karakter non-alfanumerik, normalisasi spasi
- Label encoding: MultiLabelBinarizer dengan 13 kelas
- Split data: Train 70% (709), Validation 15% (152), Test 15% (152)

#### ii. Representasi Teks

Dua representasi teks dibandingkan:

- TF-IDF: bigram (1,2), max 10.000 fitur, sublinear\_tf=True, min\_df=2
- FastText pretrained Indonesia (cc.id.300): 300 dimensi, rata-rata embedding per dokumen, sumber: Facebook AI Common Crawl

#### iii. Model Training

Dua pendekatan problem transformation dikombinasikan dengan dua algoritma dan dua representasi teks menghasilkan 16 kombinasi eksperimen:

- Binary Relevance (OneVsRestClassifier) : tiap label dilatih independen
- Classifier Chain : tiap label memperhitungkan prediksi label sebelumnya
- Algoritma: Logistic Regression (C=1 dan C=5), LinearSVC (C=1 dan C=5)
- Semua model menggunakan class\_weight='balanced' untuk menangani imbalance label

### b) Proyek B : Named Entity Recognition (NER)

#### i. Konversi Span ke BIO

- Span dari Prodigy (token\_start, token\_end inclusive) dikonversi ke format BIO per token
- Validasi offset: tidak ada token\_end out-of-bounds
- Split data: Train 70% (709), Validation 15% (152), Test 15% (152)

## ii. Tokenisasi dan Alignment

- Tokenizer: IndoBERT (indobenchmark/indobert-base-p1), WordPiece subword
- Alignment: subword pertama mendapat label BIO asli, subword lanjutan diberi -100 (diabaikan loss)
- Max length: 128 token (semua review di bawah batas ini)

## iii. Arsitektur Model

Model IndoBERT-CRF terdiri dari tiga komponen:

- IndoBERT encoder (768-dim hidden state) : 4 layer atas di-unfreeze, embedding layer dibekukan
- Linear projection:  $768 \rightarrow 27$  (jumlah BIO tag) sebagai emission score
- CRF layer (torchcrf): sequence-level decoding dengan Viterbi, menghindari tag sequence yang tidak valid

## iv. Training

- Optimizer: AdamW (lr=3e-5, weight\_decay=0.01)
- Scheduler: Linear warmup (10%) kemudian linear decay
- Max epoch: 25, Early stopping patience=5
- Batch size: 16, Gradient clipping: max\_norm=1.0

## D. Hasil Evaluasi

### a) Proyek A : Multilabel Text Classification

#### i. Perbandingan Semua Eksperimen (Validation Set)

| Eksperimen                      | Val micro-F1 | Hamming Loss | Subset Acc |
|---------------------------------|--------------|--------------|------------|
| ClassifierChain SVM_C1 TF-IDF ★ | 0.6835       | 0.0759       | -          |
| BinaryRelevance LR_C1 TF-IDF    | 0.6751       | 0.0784       | -          |
| BinaryRelevance LR_C5 TF-IDF    | 0.6724       | 0.0769       | -          |
| ClassifierChain LR_C5 TF-IDF    | 0.6653       | 0.0815       | -          |
| BinaryRelevance SVM_C1 TF-IDF   | 0.6565       | 0.0795       | -          |
| ClassifierChain SVM_C5 TF-IDF   | 0.6435       | 0.0830       | -          |
| BinaryRelevance SVM_C5 TF-IDF   | 0.6351       | 0.0820       | -          |
| ClassifierChain LR_C1 TF-IDF    | 0.6303       | 0.0926       | -          |
| ... (FastText, semua < 0.52)    | < 0.5203     | > 0.1893     | -          |

★ = Model terbaik yang dipilih untuk test set dan deployment

#### ii. Evaluasi Model Terbaik pada Test Set

Model terbaik: ClassifierChain | SVM\_C1 | TF-IDF

| Metrik | Nilai (Test Set) |
|--------|------------------|
|--------|------------------|

|                    |        |
|--------------------|--------|
| Micro-F1           | 0.6320 |
| Macro-F1           | 0.3377 |
| Weighted-F1        | 0.6176 |
| Hamming<br>Loss    | 0.0878 |
| Subset<br>Accuracy | 0.3677 |

iii. Classification Report per Label (Test Set)

| Label              | Precision | Recall | F1-Score | Support |
|--------------------|-----------|--------|----------|---------|
| PRODUCT_POSITIVE   | 0.74      | 0.77   | 0.76     | 71      |
| PRODUCT_NEGATIVE   | 0.11      | 0.14   | 0.12     | 7       |
| PRODUCT_NEUTRAL    | 0.00      | 0.00   | 0.00     | 3       |
| PRICE_POSITIVE     | 0.75      | 0.60   | 0.67     | 15      |
| PRICE_NEGATIVE     | 0.40      | 0.33   | 0.36     | 6       |
| PRICE_NEUTRAL      | 0.00      | 0.00   | 0.00     | 3       |
| PLACE_POSITIVE     | 0.70      | 0.74   | 0.72     | 43      |
| PLACE_NEGATIVE     | 0.00      | 0.00   | 0.00     | 6       |
| PLACE_NEUTRAL      | 0.67      | 0.33   | 0.44     | 6       |
| PROMOTION_POSITIVE | 0.74      | 0.65   | 0.69     | 26      |
| PROMOTION_NEGATIVE | 0.00      | 0.00   | 0.00     | 4       |
| PROMOTION_NEUTRAL  | 0.00      | 0.00   | 0.00     | 2       |
| OUT_OF_TOPIC       | 0.83      | 0.71   | 0.77     | 35      |



b) Proyek B : NER (IndoBERT-CRF)

i. Training Curve

Model dilatih selama 15 epoch sebelum early stopping (patience=5). Best checkpoint pada epoch 10.

| Epoch | Train Loss | Val F1 (Entity) | Status     |
|-------|------------|-----------------|------------|
| 1     | 2.1483     | 0.0395          | best       |
| 2     | 1.4101     | 0.0988          | best       |
| 3     | 1.0173     | 0.1285          | best       |
| 5     | 0.5655     | 0.1932          | best       |
| 7     | 0.3098     | 0.1977          | best       |
| 10    | 0.1404     | 0.2017          | best ★     |
| 15    | 0.0472     | 0.1870          | early stop |

ii. Entity-Level Evaluation (segeval) : Test Set

| Entitas      | Precision | Recall | F1-Score | Support |
|--------------|-----------|--------|----------|---------|
| OUT_OF_TOPIC | 0.0811    | 0.1579 | 0.1071   | 57      |
| PLACE        | 0.2532    | 0.2817 | 0.2667   | 71      |
| PRICE        | 0.0909    | 0.1429 | 0.1111   | 21      |
| PRODUCT      | 0.2014    | 0.3085 | 0.2437   | 94      |
| PROMOTION    | 0.2143    | 0.2647 | 0.2368   | 34      |
| micro avg    | 0.1711    | 0.2527 | 0.2041   | 277     |
| macro avg    | 0.1682    | 0.2311 | 0.1931   | 277     |
| weighted avg | 0.1831    | 0.2527 | 0.2106   | 277     |

iii. Token-Level Evaluation (B-tag only) : Test Set

| Tag | Precision | Recall | F1-Score | Support |
|-----|-----------|--------|----------|---------|
|-----|-----------|--------|----------|---------|

|                    |        |        |        |    |
|--------------------|--------|--------|--------|----|
| B-<br>OUT_OF_TOPIC | 0.5294 | 0.4737 | 0.5000 | 57 |
| B-PLACE            | 0.5965 | 0.4789 | 0.5312 | 71 |
| B-PRICE            | 0.3684 | 0.3333 | 0.3500 | 21 |
| B-PRODUCT          | 0.5056 | 0.4787 | 0.4918 | 94 |
| B-PROMOTION        | 0.5172 | 0.4412 | 0.4762 | 34 |

## E. Perbandingan Model

### a) Proyek A

#### i. Pengaruh Representasi Teks

TF-IDF secara konsisten unggul dibanding FastText pretrained pada seluruh konfigurasi. Hal ini disebabkan karakteristik dataset: review pendek (rata-rata 15 token), teks informal/noisy yang tidak sepenuhnya tercakup oleh FastText cc.id.300 yang dilatih pada corpus web umum. Mean embedding FastText kehilangan informasi urutan dan konteks lokal yang justru ditangkap lebih baik oleh TF-IDF bigram.

#### ii. Binary Relevance vs Classifier Chain

Classifier Chain sedikit lebih baik pada konfigurasi terbaik (0.6835 vs 0.6751 micro F1). Ini menunjukkan adanya korelasi antarlabel yang dapat dieksploitasi, misalnya label `PRODUCT_POSITIVE` sering muncul bersama `PROMOTION_POSITIVE`. Namun perbedaannya tidak signifikan, kemungkinan karena jumlah data yang terbatas membatasi kemampuan chain untuk belajar dependensi antarlabel secara reliabel.

#### iii. Pengaruh Parameter C

$C=1$  (regularisasi lebih kuat) umumnya lebih baik atau setara dengan  $C=5$  pada dataset berukuran kecil. Regularisasi yang lebih kuat mencegah overfitting pada fitur TF-IDF yang sparse dengan dimensi tinggi.

### b) Proyek B

Model IndoBERT-CRF mencapai entity-level micro-F1 sebesar 0.2041 dan token-level B-tag F1 rata-rata  $\sim 0.47$ . Selisih besar antara entity-level dan token-level F1 menunjukkan model cukup baik dalam mendeteksi token pertama entitas (B-tag), namun kurang presisi dalam menentukan batas akhir span (I-tag), yang merupakan pola boundary error yang umum pada NER.

| Aspek          | Proyek A (Multilabel)      | Proyek B (NER)    |
|----------------|----------------------------|-------------------|
| Level analisis | Review-level               | Token-level       |
| Model terbaik  | ClassifierChain+SVM+TF-IDF | IndoBERT-CRF      |
| Metrik utama   | micro-F1: 0.6320           | entity F1: 0.2041 |

|                 |                                                                                 |                                                |
|-----------------|---------------------------------------------------------------------------------|------------------------------------------------|
| Hamming Loss    | 0.0878                                                                          | -                                              |
| Subset Accuracy | 0.3677                                                                          | -                                              |
| Kekuatan        | Deteksi label dominan<br>(PRODUCT_POSITIVE,<br>PLACE_POSITIVE,<br>OUT_OF_TOPIC) | Token-level detection cukup<br>baik (~0.47 F1) |
| Kelemahan       | Label minoritas<br>(NEGATIVE, NEUTRAL)<br>F1=0.00                               | Entity-level span masih<br>rendah (0.20)       |

## F. Analisis Kesalahan

### a) Proyek A (Error Analysis)

#### 1. Label Imbalance sebagai Penyebab Utama

Label minoritas seperti `PRODUCT_NEGATIVE` (support=7), `PRODUCT_NEUTRAL` (3), `PRICE_NEUTRAL` (3), `PLACE_NEGATIVE` (6), `PROMOTION_NEGATIVE` (4), dan `PROMOTION_NEUTRAL` mendapatkan  $F1=0.00$  pada test set. Jumlah sampel yang sangat sedikit menyebabkan model tidak dapat belajar representasi yang cukup meskipun sudah menggunakan `class_weight='balanced'`.

#### 2. False Positive terbanyak

`PRODUCT_POSITIVE` dan `PLACE_POSITIVE` adalah label yang paling banyak menghasilkan false positive. Model cenderung over-predict label yang dominan karena prior distribusi yang tidak seimbang.

#### 3. False Negative terbanyak

Label `NEGATIVE` dan `NEUTRAL` cenderung di-miss oleh model. Contoh: review yang mengkritik harga (`PRICE_NEGATIVE`) kadang diprediksi sebagai `PRICE_POSITIVE` karena kata-kata seperti 'harga' muncul lebih sering dalam konteks positif di training data.

#### 4. Subset Accuracy Rendah (0.3677)

Hanya 36,77% prediksi yang tepat identik dengan label ground truth (exact match semua label). Ini wajar untuk multilabel dengan banyak kelas, namun menunjukkan bahwa model masih kesulitan memprediksi kombinasi label yang tepat, terutama untuk review dengan 3+ label aktif.

## b) Proyek B (Error Analysis NER)

### 1. Boundary Error

Boundary error adalah tipe kesalahan paling umum: model mendeteksi entitas yang benar secara label tetapi salah menentukan batas token. Ini terjadi karena token\_end dalam anotasi Prodigy bisa mencakup beberapa kata yang terhubung secara sintaktis, sedangkan model seringkali berhenti lebih awal atau lebih akhir dari ground truth span.

### 2. Label Error

Label error terjadi saat aspek terdeteksi dengan benar tetapi sentimennya salah (misalnya memprediksi PRODUCT\_POSITIVE ketika ground truth PRODUCT\_NEGATIVE). Hal ini terutama terjadi pada kalimat ironi atau konteks yang ambigu.

### 3. Entity-Level vs Token-Level Gap

Token B-tag F1 (~0.47) jauh lebih tinggi dari entity-level F1 (0.20). Ini mengindikasikan model cukup baik dalam mengidentifikasi awal entitas, tetapi sequeval menghitung seluruh span harus tepat (exact match boundary dan label) agar dihitung sebagai benar.

### 4. Dataset Kecil

Total 1.013 record dengan distribusi token non-O sekitar 27% menjadi keterbatasan utama untuk NER berbasis IndoBERT. Fine-tuning Transformer memerlukan data yang lebih besar (setidaknya 5.000–10.000 sampel) untuk mencapai performa yang baik, terutama untuk entitas minoritas seperti PRICE dan PROMOTION.



## G. Referensi Pretrained Model

| Model                                             | Sumber                                                                         | Alasan Penggunaan                                                                                                                                                                                                                                                                                                                  |
|---------------------------------------------------|--------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| IndoBERT<br>(indobert-base-p1)                    | HuggingFace Hub:<br>indobenchmark/indobert-base-p1 (Wilie et al., 2020)        | Model BERT yang dilatih khusus pada korpus Bahasa Indonesia (Wikipedia, berita, web) sehingga memiliki pemahaman konteks Bahasa Indonesia yang jauh lebih baik dibanding multilingual BERT. Digunakan sebagai encoder untuk Proyek B (NER) karena dataset review berbahasa Indonesia membutuhkan representasi subword yang sesuai. |
| FastText<br>cc.id.300<br>(Common Crawl Indonesia) | Facebook AI Research:<br>fasttext.cc/crawl-vectors-165/id (Grave et al., 2018) | Word embedding 300 dimensi berbasis subword n-gram yang dilatih pada Common Crawl Bahasa Indonesia. Digunakan sebagai representasi teks alternatif pada Proyek A (Multilabel Classification) untuk dibandingkan dengan TF-IDF. Kelebihan FastText adalah kemampuan menangani kata OOV melalui subword n-gram.                      |

## H. Screenshot Deployment

Aplikasi Streamlit terpadu dengan tiga tab: Prediksi Multilabel ABSA, Prediksi NER ABSA, dan Tentang Aplikasi.

### a) Tab Prediksi Multilabel ABSA





## b) Tab Prediksi NER ABSA

Aspect-Based Sentiment Analysis dari Review Google Places — Multilabel Text Classification & Named Entity Recognition

Prediksi Multilabel ABSA

Prediksi NER ABSA

Tentang Aplikasi

### Prediksi NER ABSA (Token-Level Span Extraction)

Model mengenali span dalam teks yang merujuk pada aspek ABSA (Product, Price, Place, Promotion) beserta sentimennya.

Masukkan teks review:

tempat nyaman  
harga murah

Ekstrak Entitas

#### Visualisasi Span

tempat PLACE POSITIVE    nyaman harga murah PRICE POSITIVE

#### Entitas Terdeteksi

| Span               | Label          | Aspek | Sentimen |
|--------------------|----------------|-------|----------|
| tempat             | PLACE_POSITIVE | PLACE | POSITIVE |
| nyaman harga murah | PRICE_POSITIVE | PRICE | POSITIVE |

#### Legenda Warna Span

PRODUCT\_POSITIVE

PRICE\_POSITIVE

PLACE\_POSITIVE

PROMOTION\_POSITIVE

PRODUCT\_NEGATIVE

PRICE\_NEGATIVE

PLACE\_NEGATIVE

PROMOTION\_NEGATIVE

PRODUCT\_NEUTRAL

PRICE\_NEUTRAL

PLACE\_NEUTRAL

PROMOTION\_NEUTRAL

Manage app

## c) Tab About

ABSA Review Analyzer

Aspect-Based Sentiment Analysis dari Review Google Places — Multilabel Text Classification & Named Entity Recognition

Prediksi Multilabel ABSA

Prediksi NER ABSA

Tentang Aplikasi

### Tentang Aplikasi

Proyek UAS Pengolahan Bahasa Alami

Universitas Aries Jaya Yogyakarta — Grup 26052006

Aplikasi ini merupakan deployment dari dua model NLP yang dikembangkan untuk analisis review Google Places berbahasa Indonesia menggunakan pendekatan Aspect-Based Sentiment Analysis (ABSA).

#### Proyek A — Multilabel Text Classification

| Komponen     | Detail                                                          |
|--------------|-----------------------------------------------------------------|
| Task         | Memprediksi label ABSA pada level review (multi-hot)            |
| Representasi | Tf-IDF dengan L2R-Flow & FastText pretrained Indonesia (v1.0.0) |
| Pendekatan   | Binary Relevance & Classifier Chain                             |
| Algoritma    | Logistic Regression, LinearSVC                                  |
| Output       | Kombinasi 13 label aspek sentimen                               |

#### Proyek B — Named Entity Recognition (NER)

| Komponen  | Detail                                            |
|-----------|---------------------------------------------------|
| Task      | Mengidentifikasi span aspek ABSA pada level token |
| Model     | IndoBERT (IndonesianBERT) dengan span-p1 + CRF    |
| Skema tag | BIOES-3-IO dengan 13 label entitas                |
| Decoding  | Viterbi naïve CRF layer                           |
| Output    | Span token dengan label aspek sentimen            |

#### Hubungan Output Multilabel ↔ NER

Output kedua model saling melengkapi:

- Multilabel mengungkap "aspek apa yang didiskusikan?" pada level review
- NER mengungkap "di bagian mana terdapat?" pada level token/span

Contoh jika Multilabel memprediksi `PRICE_POSITIVE`, NER akan menyorotkan span kalimat spesifik seperti "ternyata murah" yang menjadi dasar prediksi tersebut.

Manage app

## I. Pembagian Tugas Anggota Kelompok

| Tugas                                   | Dikerjakan Oleh                 |
|-----------------------------------------|---------------------------------|
| Data loading & preprocessing            | Ferrincia Avril (230712368)     |
| EDA & visualisasi                       | Ferrincia Avril (230712368)     |
| Feature engineering (TF-IDF & FastText) | Ferrincia Avril (230712368)     |
| Training model multilabel               | Ferrincia Avril (230712368)     |
| Evaluasi & error analysis multilabel    | Ferrincia Avril (230712368)     |
| Konversi span ke BIO & NER dataset      | Beyond Revata Hwang (230712326) |
| Training IndoBERT-CRF                   | Beyond Revata Hwang (230712326) |
| Evaluasi & error analysis NER           | Beyond Revata Hwang (230712326) |
| Pengembangan aplikasi Streamlit         | Beyond Revata Hwang (230712326) |
| Penulisan laporan                       | Ferrincia Avril (230712368)     |
| Pembuatan video                         | Beyond Revata Hwang (230712326) |